

Esquema del IPM-SAE-CEPAL

24 de febrero de 2022

Supondremos, para simplificar el ejemplo, que el indicador de interés está compuesto por tres variables: una disponible en el censo (y_1) y dos que deben ser predichas para cada unidad en el censo. Además, de las dos variables no observadas, una es discreta dicotómica (y_2) y la otra es una función del ingreso laboral (y_3).

Por la naturaleza de estas últimas dos variables, el enfoque de modelación, estimación y predicción deberá adaptarse apropiadamente al estado de la cuestión de los modelos. Esto es, la variable y_2 será modelada a través de un modelo EPP (*empirical plug-in*), mientras que la variable y_3 será modelada con un EBP (*empirical best/bayes*).

En primera instancia, cada uno de los dos modelos se ajusta en la encuesta, usando los datos disponibles en BADEHOG. A partir de estos modelos tendremos estimaciones para los parámetros de regresión y para los efectos aleatorios a nivel de municipio (obviamente, diferentes para cada modelo 🤔). Al contrario de lo que se plantea en los ejercicios regulares de SAE para ingresos, pobreza o cualquier otro indicador individual, nuestro propósito no es obtener medidas de resumen predictivas sobre cada variable y_2 , y_3 , sino utilizar su predicción, en conjunto con la variable observada y_1 para, a su vez, obtener predicciones de la privación del individuo en la dimensión.

El modelo EPP afirma que y_2 sigue la siguiente distribución de probabilidad

$$y_{di} | y_{ds} \sim N(\mu_{d:is}, \sigma_{d:is}^2)$$

El modelo EBP afirma que y_3 sigue la siguiente distribución de probabilidad

$$y_{di} | u_d \sim \text{Ber}(p_{di})$$

Por lo tanto, utilizando un enfoque paramétrico, haremos uso de los métodos de simulación para obtener estas predicciones, no solo una vez, sino muchas veces. De esta forma, cada iteración del Monte Carlo EPP inducirá una predicción para y_2 y cada iteración del Monte Carlo EBP inducirá una predicción para y_3 . Así se vería la base de datos super-ampliada para las J iteraciones de Monte Carlo:

K	y_{-1}	$y_{-2}^{(1)}$	$y_2^{(2)}$	\dots	$y_2^{(J)}$	$y_3^{(1)}$	$y_3^{(2)}$	\dots	$y_3^{(J)}$
1	1	1	0	\dots	1	0	1	\dots	1
2	1	0	1	\dots	1	1	1	\dots	1
\vdots	\vdots	\vdots	\vdots	\ddots	\vdots	\vdots	\vdots	\ddots	\vdots
N	0	1	0	\dots	0	0	1	\dots	0

Los colores nos sirven para enfatizar que cada bloque (verde y azul) proviene de una medida de probabilidad diferente (EPP y EBP, respectivamente). Ahora, la variable y_{-1} , junto con la primera iteración de los Monte Carlos dará origen a una predicción del IPM para todos los individuos. Así sucesivamente para las J realizaciones de la anterior gráfica, tendríamos la siguiente estructura para el IPM:

K	$IPM^{(1)}$	$IPM^{(2)}$	\dots	$IPM^{(J)}$	$E(IPM)$
1	1	0	\dots	1	0.87
2	1	1	\dots	1	0.23
\vdots	\vdots	\vdots	\ddots	\vdots	\vdots
N	1	0	\dots	0	0.04

!!!!ACÁ ESTÁ LA GRAN CONTRIBUCIÓN DEL PAPER!!!!

Utilizando este conjunto de datos simulados, fácilmente se llegan a las estimaciones municipales del IPM, utilizando la esperanza como predictor (de forma similar a un EPP). Acá valdría la pena verificar si es que este IPM puede verse como una realización de una variable aleatoria Bernoulli, puesto que al final cada individuo en el censo tendrá una probabilidad de ser pobre multidimensional.

La estimación de ECM debería seguir los principios de González-Manteiga et. al. (2007), que podría ser resumido de la siguiente manera:

1. Ajustar el EPP y el EBP a los datos de la muestra, obteniendo todos los estimadores necesarios.
2. Generar efectos aleatorios EPP, efectos aleatorios EBP y errores EBP.
3. Generar dos pseudo-censos Bootstrap, uno para y_1 y otro para y_2 .
4. Seleccionar una muestra Bootstrap, siguiendo los lineamientos de la muestra original.
5. Ajustar modelos EBP y EPP, apropiadamente a los pseudo-censos y calcular los predictores del IPM.
6. Repetir B veces y calcular la estimación del ECM.
7. Cruzar los dedos para que esto se ejecute rápido.

¡¡¡Y listo!!!